Программная система «Ищейка»
Отчёт о состоянии разработки

Основание: ТЗ на создание мультиагентной интернет-системы аналитики, прогнозирования и риск-оценки «Ищейка», редакция 4.0 · Дата: 20.08.2026 · Стадия: MVP работает на живой языковой модели · Кодовая база: 51 модуль, 35 автотестов

> **Кратко.** Система работает на живой языковой модели и выдаёт содержательные отчёты. Полный цикл: 13 агентов из 13, 25 источников из четырёх поисковых движков, S-кривая на фактических данных, экспорт в HTML, DOCX и PDF. Оба блокирующих вопроса прошлой редакции сняты: канал поиска перестроен на бесплатные официальные API, LLM подключён на свободном тарифе Groq. **Открытые вопросы теперь касаются не работоспособности, а масштаба и полноты:** платный веб-поиск для неакадемических источников, патентные базы, целевая нагрузка.

> **Что подтверждено живым прогоном** (запрос «Оцени перспективы твердотельных аккумуляторов для электромобилей до 2035 года», режим comprehensive, все 13 агентов отработали без сбоев): план из шести двуязычных запросов · 20 источников из трёх поисковых движков · TRL 7 с обоснованием и ссылками на конкретные источники · 5 характеристик со сравнением с аналогами · S-кривая по 25 фактическим точкам OpenAlex, R^2 = 0.991, точка перегиба 2031 г. · 12 сценариев по четырём горизонтам · 8 рисков с мерами снижения · 2 замечания критика и 5 контраргументов Red Team · 5 рекомендаций и 11 честно перечисленных нерешённых вопросов · итоговая уверенность 40 % · отчёт на русском в HTML, DOCX и PDF.

1. Что сделано

Раздел ТЗ	Реализовано	Проверено
5. Состав агентов	Все 13 агентов W01–W13 с единым контрактом `execute(context) → result`	**да** — `/api/v1/agents` возвращает 13 агентов с зависимостями
4. Архитектура, 6. Процессы	Mission Core: нормализация → память → декомпозиция → DAG → параллельные уровни → аудит → критика → синтез → отчёт → память	**да** — сквозной прогон миссии, 16 шагов ТЗ 4.3 отработали
5.1. Поиск	Шлюз с параллельным опросом, агрегацией, дедупликацией и ранжированием по релевантности. Без ключей: OpenAlex, Crossref, Semantic Scholar, arXiv, PubMed, DuckDuckGo, патенты	**да** — 25 источников из 4 движков за прогон. Общий веб-поиск ограничен (п. 3.2)
5.2. Техоценка	TRL 1–9 с обоснованием, таблица характеристик, сравнение с аналогами	**да** — на живом прогоне TRL 5 с обоснованием и ссылками на источники
5.3. Форсайт	S-кривая на фактической динамике публикаций OpenAlex, три сценария на горизонты 1–20 лет, доверительные интервалы	**да** — на живых данных 25 точек, R^2 = 0.991, точка перегиба 2031

5.4. Риски	5 типов рисков, матрица 5×5, экспозиция, уровень, меры снижения, контроль полноты покрытия типов	**да** — 6 рисков по 5 типам, матрица строится
5.5. Достоверность	Ссылка и дата у каждого источника, авторитетность домена, уверенность по 5 факторам со штрафами за критику	**да** — расчёт покрыт тестами
6.7–6.9. Взаимная проверка	Evidence Auditor, Critic, Red Team, автоматическое выявление противоречий между агентами	**да** — конфликты детектируются и попадают судье
6.12. Отчёты	HTML с графиками, DOCX (python-docx), PDF (браузер / ReportLab)	**да** — 7 страниц PDF, кириллица корректна
6.2, 11.11–11.13. Память	Семантический поиск по прошлым миссиям, автосохранение выводов, граф связей supports/contradicts/derived_from	**да** — 10 записей и 9 связей на миссию
5.1. Документы пользователя	Загрузка PDF/DOCX/TXT, текст идёт агентам и в перечень источников отчёта	**да** — из тестового PDF извлечены и попали в выводы 420 Вт·ч/кг, 800 циклов, 310 USD/кВт·ч
3.6. Human-in-the-loop	Подтверждение и отклонение выводов; отклонённое стирается из памяти вместе со связями	**да** — проверено на живой миссии
9. Кэш внешних запросов	Выдача движков и ответы модели кэшируются на час, статистика в /health	**да** — повторный поиск 0,55 с → мгновенно
7.8. Повторный запуск миссии	Кнопка в истории, параметры берутся из исходной миссии	**да**
8. Безопасность	JWT (24 ч), bcrypt, RBAC (admin/analyst/guest), rate limiting 100/мин, журнал аудита	**да** — покрыто тестами, гость получает 403
10. API	Все эндпоинты ТЗ 10.1 + WebSocket-поток событий ТЗ 10.2	**да** — 21 маршрут, Swagger доступен
11. Модель данных	Все таблицы 11.1–11.13 плюс documents	**да** — схема создаётся, данные раскладываются по таблицам

Контроль качества

35 автоматических тестов (аналитика, поиск, API) — все проходят. Отдельный сквозной прогон миссии без сети (`tests/e2e_check.py`) подтверждает работу конвейера целиком. Тесты герметичны: в интернет не ходят.

2. Критерии готовности MVP (ТЗ 13.2)

Критерий	Статус	Комментарий
Пользователь создаёт миссию, поиск идёт по интернету (минимум 2 системы)	**выполнен**	4 движка без ключей
Запускается минимум 5 агентов, формируется отчёт с резюме, анализом, прогнозом, рисками	**выполнен**	запускаются все 13
Каждый факт имеет ссылку на источник с датой и авторитетностью	**выполнен**	раздел 7 отчёта
Отчёт скачивается в Word и PDF	**выполнен**	плюс HTML

Ключевые факты сохраняются в память	**выполнен**	автоматически после W13
При новом запросе предлагаются результаты похожих прошлых миссий	**выполнен**	событие MEMORY_HIT
Время обработки ≤ 5 минут	**выполнен**	полный цикл ≈ 60–90 с
Интерфейс: история миссий и скачивание отчёта	**выполнен**	встроенная веб-страница

> Все восемь критериев MVP выполнены и подтверждены живым прогоном на реальной языковой модели. Единственная оговорка касается сроков: на свободном тарифе (8000 токенов в минуту) полная миссия занимает 5–8 минут вместо требуемых ТЗ пяти; сокращённый режим `quick` укладывается в две. Это ограничение тарифа, а не архитектуры.

3. Найденные дефекты и что с ними сделано

Ниже — только дефекты, обнаруженные проверкой и живыми прогонами, а не гипотезы. Все перечисленные исправлены и закреплены тестами.

3.1. Исправлено при проверке кода

Дефект	Проявление	Решение
PDF нечитаем	Файл создавался и считался успехом, но вся кириллица печаталась пустыми плашками: xhtml2pdf на Windows не может передать TTF-шрифт в reportlab	xhtml2pdf исключён из цепочки. Порядок: WeasyPrint → headless-браузер → ReportLab с явной регистрацией шрифта. Оба рабочих пути проверены
Режим `quick` не работал	Разворачивался во все 13 агентов вместо 6: замыкание зависимостей шло по рёбрам порядка, а не обязательности	Разделены `DEPENDENCIES` (порядок выполнения) и `REQUIRES` (обязательность входа)
Патентный агент W02 обесточен	Всегда возвращал 0 патентов: движок `patents` не входил в конфигурацию по умолчанию	Движок включён в набор по умолчанию
Источники перестали различаться	Все научные публикации получали надёжность 0.99: надбавки складывались без ограничения, а `doi.org` оценивался как издатель, хотя это лишь резолвер ссылок	Суммарная надбавка ограничена +0.15, `doi.org` понижен до 0.72. Разброс восстановлен: 0.95 / 0.87 / 0.25
Молчаливый отказ поиска	При антибот-заглушке DuckDuckGo движок возвращал пустой список, и система считала, что по запросу просто ничего не нашлось	Заглушка распознаётся, выполняется повтор, затем отказ пишется в журнал явным текстом

3.2. Найдено и исправлено на живых прогонах с моделью

Эти дефекты невозможно было увидеть на заглушке — они проявились только при работе с реальной моделью и реальными лимитами провайдера.

Дефект	Проявление	Решение
Планировщик отменял выбор пользователя	Миссия запрошена в режиме «все 13 агентов», отрабатывали шестеро: модель предлагала сокращённый состав, и её предложение молча перекрывало явное указание. Отчёт выходил без TRL, рисков и прогноза	Приоритет закреплён: явный список из запроса → режим → предложение модели, которое может только расширять набор. Заодно поле `agents` из API впервые дошло до планировщика: раньше оно принималось и игнорировалось
Отчёт на английском по русскому запросу	Источники англоязычные, и без явного указания модель уходила на их язык: заказчик получал отчёт, который не может прочитать	Директива языка выводится из языка запроса миссии и добавляется в промпт каждого агента
Прогноз не строился	Временной ряд просили у модели — она возвращала пустой список: в научных статьях таких таблиц нет, а выдуманные числа невоспроизводимы	Ряд берётся из OpenAlex одним запросом (динамика публикаций по годам) — фактические счётчики. Текущий год отбрасывается как неполный

Пять агентов из тринадцати падали с 429	Провайдер списывает из минутного лимита **полный** `max_tokens`, а не размер ответа: запрос с лимитом 2048 и ответом в 300 токенов съедает 2048. Оценка «по типичному размеру» систематически занижала стоимость	Учёт приведён к правилам провайдера, экономия перенесена в сами промпты: выжимка источников сокращена с 2590 до 658 токенов, `max_tokens` до 1024. Результат: 13/13 агентов, ноль отказов
Суточный лимит «лечился» ожиданием	При исчерпании дневной квоты провайдер шлёт `x-should-retry: false` и просит вернуться через часы. Код повторял вслепую, и наружу шло «таймаут агента» вместо понятной причины	Такой отказ распознаётся и объясняется сразу: «исчерпан суточный лимит токенов модели»

3.3. Нестабильность поиска — решено без ключей

Ставка на DuckDuckGo как на единственный канал была ошибкой проектирования: это единственный источник, который разбирает HTML, и потому единственный, кого блокируют. Подключены официальные бесплатные API, ключей не требующие:

Движок	Ключ	Что даёт
OpenAlex	не нужен	~250 млн научных работ, число цитирований, издатель
Semantic Scholar	не нужен	аннотации и цитируемость (общий лимит, отвечает со второй попытки)
Crossref	не нужен	метаданные по DOI, цитируемость; включён вежливый пул
arXiv, PubMed	не нужны	препринты и биомедицина
SearXNG	свой инстанс	метапоиск по Google/Bing/DDG сразу. Публичные зеркала проверены — нестабильны, поэтому по умолчанию выключен

Дополнительно: индивидуальные паузы под лимиты каждого API (после подключения новых движков Crossref и PubMed начали отвечать 429 — это было исправлено), и главное — **ранжирование по релевантности**. Раньше выдача сортировалась по авторитетности, и в топ выходили цитируемые работы не по теме.

> **Замерено на одном и том же запросе:** с только русской формулировкой — 9 источников из 1 домена, средняя релевантность 0.48. С двуязычным планом запросов — **25 источников из 3 доменов, четыре движка, средняя релевантность 0.98**, все по теме.

> **Что осталось.** DuckDuckGo с этого адреса отдаёт 403 — общий веб-поиск (новости, рынок, отраслевые отчёты) по-прежнему ненадёжен, но он больше не критичен: научная и патентная доказательная база собирается без него. Ключ Google CSE или SerpAPI остаётся желательным, но перестал быть блокирующим.

4. Что требуется от вас

Ниже — всё, что нельзя сделать со стороны разработки. Для каждого пункта: что именно нужно, где это берётся, во что обходится и что даёт. Пункты 1 и 2 определяют, можно ли вообще выпускать систему в эксплуатацию; остальные расширяют охват.

№	Что нужно	От вас	Стоимость	Срочность
1	Решение по конфиденциальности запросов	Позиция службы безопасности	—	**до эксплуатации**
2	Тариф языковой модели	Оплата или второй бесплатный ключ	от 0 до ~2 000 ₽/мес	**до эксплуатации**
3	Контрольные запросы вашей предметной области	5–10 формулировок	—	**до приёмки**
4	Ключ поискового API	Регистрация	0 на пилоте	**высокая**
5	Доступ к патентным базам	Регистрация, для Роспатента — договор	0 / по договору	**средняя**
6	Сервер и инфраструктура под 50 сессий	Машина, Redis, PostgreSQL	инфраструктура	средняя
7	Решение по OCR	Разрешение на установку Tesseract	0	низкая
8	Решение по интерфейсу и сценарию аналитика	Требования	—	низкая

1. Конфиденциальность запросов — вопрос, который стоит решить первым

> Система предназначена для **технологической разведки**. Это значит, что сам запрос — «оцени перспективы такой-то технологии», «выяви риски внедрения такого-то изделия» — раскрывает, чем именно вы интересуетесь. Сейчас запросы уходят на серверы Groq (США), а поисковые запросы — в OpenAlex, Crossref, PubMed.
>
> **Что нужно от вас:** позиция службы безопасности по вопросу «допустимо ли отправлять формулировки исследовательских задач во внешние сервисы».
>
> **Варианты, если недопустимо:**
>
> - **Локальная модель через Ollama.** Ничего не уходит наружу, кроме поисковых запросов. Я проверил эту машину: 32 ГБ памяти, 8 ядер Xeon, но **видеокарты нет** — миссия займёт 10–20 минут вместо полутора, качество анализа и критики заметно ниже. Для приемлемой скорости нужен сервер с GPU (от 24 ГБ видеопамяти).
> - **Обезличивание запросов** — формулировать миссии в общих терминах отрасли, не называя конкретные изделия. Снижает точность поиска.
> - **Развёртывание в закрытом контуре** с локальной моделью и зеркалами научных баз. Самый дорогой путь, но единственный полностью закрытый.
>
> Пока такого решения нет, я исхожу из того, что запросы не составляют тайны. **Если это не так — скажите, и приоритеты меняются полностью.**

2. Тариф языковой модели

Сейчас: свободный тариф Groq, модель `openai/gpt-oss-120b`. Лимиты — 8 000 токенов в минуту и 200 000 в сутки на каждую модель.

Что это означает практически: полная миссия из тринадцати агентов тратит около 30 000 токенов и идёт 5–8 минут (требование ТЗ 9 — до 5 минут). В сутки помещается примерно **шесть полных миссий** на модель. Сокращённый режим `quick` — около двух минут и втрое дешевле.

Варианты:

- **Остаться на свободном тарифе.** Ничего не платите. Годится для демонстраций и отладки, не годится для работы отдела. Смягчение: система уже умеет переключаться между моделями при исчерпании суточной квоты, а кэш не даёт повторным прогонам выедать её впустую.
- **Платный тариф Groq (Dev Tier).** Снимает и минутный, и суточный лимит. Миссия — полторы минуты. Ориентировочно единицы долларов за сотню миссий: модель дешёвая, а миссия тратит около 30 тысяч токенов.
- **Второй и третий бесплатные ключи** — Google Gemini (1500 запросов в сутки) и OpenRouter. Адаптеры уже написаны, переключение — строка в настройках. Даёт втрое больший суточный запас бесплатно.

Что нужно от вас: либо оплата тарифа, либо ключи Gemini и OpenRouter (регистрация по 2 минуты, карта не нужна).

3. Контрольные запросы вашей предметной области

Это самое ценное, что вы можете дать, и это ничего не стоит.

Сейчас система откалибрована на общих формулировках вроде «перспективы твердотельных аккумуляторов». Промпты тринадцати агентов настроены на такой материал. Ваши реальные задачи наверняка формулируются иначе: другая отрасль, свои термины, свои критерии оценки, свои источники, которые вы считаете авторитетными.

Что нужно от вас: 5–10 формулировок реальных задач, с которыми вы пойдёте в систему, и — если есть — примеры отчётов, которые ваши аналитики считают хорошими.

Что это даст: я прогоню их, посмотрю, где агенты промахиваются, и подстрою промпты. Без этого настройка ведётся вслепую: система будет уверенно отвечать на вопросы, которых вы не задаёте.

4. Ключ поискового API

Сейчас: научные базы работают надёжно и без ключей — OpenAlex, Crossref, Semantic Scholar, arXiv, PubMed. Общий веб-поиск через DuckDuckGo нестабилен: с этого адреса он отвечает отказом антибот-защиты.

Чего не хватает без него: новостей, рыночных отчётов, сайтов производителей, отраслевой аналитики. То есть всего, что не является научной публикацией. Агент W04 (рынок) работает на голодном пайке, патентный поиск W02 — тоже.

Варианты:

- **Google Custom Search** — console.cloud.google.com, 100 запросов в сутки бесплатно, дальше 5 долларов за 1000. Для пилота достаточно бесплатной квоты. Нужны два значения: ключ API и идентификатор поисковой системы (cx).
- **SerpAPI** — serpapi.com, платный, снимает вопрос лимитов и блокировок полностью.
- **Свой инстанс SearXNG** — метапоиск по Google, Bing и DuckDuckGo сразу, разворачивается одним контейнером в вашем контуре, ключей не требует. Адаптер написан, публичные зеркала я проверил — они нестабильны, а свой инстанс решает и это, и вопрос конфиденциальности поисковых запросов.

Что нужно от вас: выбрать вариант. Интеграции всех трёх уже в коде, включение — строка в настройках.

5. Патентные базы

Сейчас: патенты ищутся обычным веб-поиском по `patents.google.com` и наследуют все его проблемы. В последних прогонах патентный агент честно сообщал, что документов не нашёл — а критик справедливо замечал, что это противоречит действительности: патенты на эти технологии существуют.

Варианты:

- **USPTO PatentsView** — patentsview.org, ключ бесплатный по заявке, только патенты США. Самый быстрый путь.
- **Espacenet OPS** (Европейское патентное ведомство) — developers.epo.org, бесплатный тариф с лимитами, мировые данные. Нужны два значения: ключ и секрет.
- **Роспатент** — для российских патентов, требует договора с ФИПС.

Что нужно от вас: регистрация в одной или двух базах и передача ключей; для Роспатента — юридическое оформление. **Что это даст:** реальный патентный ландшафт вместо честного «не найдено»: активность по годам, ключевые правообладатели, оценка патентоспособности.

6. Сервер и инфраструктура под заявленную нагрузку

Сейчас: очередь задач — внутри процесса приложения, база — SQLite. Этого достаточно для одного аналитика и демонстраций. Требование ТЗ 9 о пятидесяти одновременных сессиях так не закрывается.

Что нужно: сервер с Redis (очередь Celery) и PostgreSQL с расширением pgvector (основное хранилище и векторный поиск памяти). Оба разворачиваются контейнерами; переход предусмотрен архитектурой — контракт задачи совпадает с ТЗ 14.1, и замена затрагивает один модуль.

Что нужно от вас: сама машина и ответ на вопрос, какая нагрузка нужна на старте. Если пятьдесят сессий требуются сразу — это отдельный этап работ с нагрузочным тестированием (этап 12 ТЗ). Если на первое время достаточно нескольких аналитиков, текущей конфигурации хватит, и этот пункт откладывается.

7. OCR для сканированных документов

Сейчас: из PDF извлекается текстовый слой. Скан без текстового слоя даёт ноль символов — система об этом честно сообщает в отчёте, но извлечь ничего не может.

Что нужно: установка Tesseract с русским языковым пакетом. Пакет бесплатный, но ставится вне `pip` — это системная установка, влияющая на процедуру развёртывания.

Что нужно от вас: ответ на вопрос, ожидается ли работа со сканами. Если ваши документы — обычные PDF и DOCX, пункт можно закрыть как ненужный.

8. Сценарий работы аналитика и решение по интерфейсу

Здесь мне не хватает не ресурса, а понимания, как работает ваш аналитик.

- **Human-in-the-loop.** Базовая версия сделана: утверждения можно принять или отклонить, отклонённое стирается из памяти. Дальше возможны версионность отчёта, история правок, комментарии, повторный прогон с учётом правок — но какой из этих механизмов нужен, зависит от вашего процесса.
- **Интерфейс.** Текущая веб-страница закрывает все критерии MVP. ТЗ 12 предполагает React + TypeScript. Если это требование обязательно к исполнению — скажите, и я сделаю; если важнее содержание отчётов, ресурс разумнее вложить туда.
- **Роли и пользователи.** Реализованы администратор, аналитик и гость. Нужно понимать, сколько человек и с какими правами будет работать: от этого зависит, нужна ли интеграция с вашим каталогом пользователей.

> **Если коротко.** Чтобы система заработала в вашем контуре, от вас нужны три вещи: **позиция по конфиденциальности запросов** (пункт 1), **решение по тарифу модели** (пункт 2) и **пять-десять реальных формулировок задач** для калибровки (пункт 3). Первые два определяют, можно ли выпускать систему в работу; третье определяет, будет ли она полезной именно вам. Всё остальное — расширение охвата и может делаться постепенно.

5. Что делать дальше

№	Работа	Зависит от	Эффект
1	**Подключить ключ LLM — выполнено (Groq)**	—	Содержательные отчёты получены
2	Прогнать контрольные запросы из ТЗ 6 (изделие, форсайт, статья, риски) и откалибровать промпты	—	Качество TRL, рисков, прогнозов
3	Решить по тарифу LLM: остаёмся на свободном или переходим на платный	Раздел 4, п. 2	Время миссии 5–8 мин → 1,5 мин
4	Подключить поисковый API для неакадемических источников	Раздел 4, п. 4	Новости, рынок, отраслевые отчёты
5	Официальные патентные базы для W02	Раздел 4, п. 5	Реальный патентный ландшафт
6	Celery + Redis + PostgreSQL/pgvector	Раздел 4, п. 6	Масштаб до 50 сессий
7	Нагрузочное тестирование (этап 12 ТЗ)	Работа 6	Подтверждение требований ТЗ 9
8	**Human-in-the-loop — выполнено**	—	Аналитик правит выводы, память очищается
9	OCR, React, интеграция с каталогом пользователей	Раздел 4, п. 7–8	Закрытие оставшихся пунктов ТЗ

Главное. Система прошла путь от каркаса до работающего продукта: она принимает запрос, сама строит план поиска на двух языках, собирает доказательную базу из открытых научных источников, оценивает их надёжность, строит прогноз на фактических данных, критикует собственные выводы и выдаёт отчёт с честно посчитанным уровнем достоверности. Оба блокирующих вопроса прошлой редакции сняты. **Дальнейшая работа — не про работоспособность, а про полноту и масштаб:** калибровка промптов на контрольных запросах ТЗ, патентные базы, платный поиск, переход на Celery и PostgreSQL под заявленные пятьдесят сессий.